Mortalidad Materna: Un Modelo de Clasificación y Agrupamiento para el Seguimiento de la Agenda 2030

Proyecto final | Ciencia de Datos Avanzada

1. Introducción y Justificación del Problema

1.1. Definición del Problema

La Razón de Mortalidad Materna (MMR) es el número de muertes maternas por cada 100,000 nacidos vivos. Este proyecto describe cómo ha cambiado la MMR a nivel mundial entre 1990 y 2021, con énfasis en identificar países donde la MMR sigue siendo alta o donde el progreso se ha frenado. El foco es generar evidencia útil para orientar prioridades (dónde poner más atención, qué países están estancados y cuáles mejoran con mayor consistencia) y posteriormente analizar determinantes de mejora.

1.2. Importancia Social

Este modelo transforma la vigilancia de la salud materna de un enfoque reactivo a uno proactivo, permitiendo que organismos como la OMS y la OPS identifiquen no solo dónde hay crisis, sino dónde hay estancamiento. Al clasificar a 185 países por perfiles de riesgo, el sistema garantiza que los recursos internacionales se asignen con equidad técnica, evitando el costo social de retirar apoyo prematuramente.

1.3. Objetivos

- Construir un ranking/semáforo simple de países según nivel actual de MMR, ritmo de mejora y señales de estancamiento en los últimos años.
- Estimar, a grandes rasgos, qué países están más lejos de una meta de referencia como reducir la MMR a <70 por cada 100,000 nacidos vivos, como apoyo para priorización.
- Agrupar países por trayectorias.

2. Estado Actual y Brecha

Actualmente, la vigilancia de la mortalidad materna se limita a reportes estáticos y reactivos basados en umbrales fijos que ignoran la trayectoria real de los países. Esta brecha impide detectar retrocesos o estancamientos a tiempo, derivando en una asignación de recursos ineficiente. El Machine Learning aporta valor al integrar múltiples dimensiones (estado, tendencia y metas) en un análisis de Clustering, transformando datos pasivos en un sistema de alerta proactiva que optimiza la ayuda internacional y garantiza intervenciones oportunas.

3. Datos y Análisis Exploratorio

3.1. Descripción de los Datos

Los datos provienen del dataset "Maternal Mortality Dataset" disponible en Kaggle, compilado por el Grupo Interinstitucional de Estimación de la Mortalidad Materna (MMEIG), integrado por la OMS, el Banco Mundial y UNICEF. La Razón de Mortalidad Materna (MMR) se define como el número de muertes maternas por cada 100,000 nacidos vivos.

El dataset cubre el período 1990–2021 en formato anual. La unidad de análisis es país-año, con observaciones para aproximadamente 195 territorios a lo largo de 32 años, lo que genera alrededor de 6,240 registros potenciales. Las variables disponibles incluyen MMR por año, código ISO3, país, continente, hemisferio, grupos de desarrollo humano (HDI), regiones UNDP y el ranking HDI 2021.

3.2. Limpieza y Preparación

Se identificaron 11 territorios —entre ellos Andorra, Hong Kong SAR y Dominica— sin ningún registro histórico de MMR entre 1990 y 2021. Dado que la ausencia de datos en estos casos no es aleatoria, fueron eliminados del análisis en lugar de imputar valores que carecerían de respaldo empírico.

Adicionalmente, dos países sin clasificación en el Índice de Desarrollo Humano (IDH) fueron excluidos, quedando una muestra final de 182 países. Los valores faltantes dentro de la serie temporal de MMR tampoco fueron imputados: una ausencia de dato puede reflejar conflicto o ruptura del sistema de salud, y cualquier imputación introduciría un sesgo estructural.

En cuanto a outliers, la distribución de MMR presentó un sesgo derecho pronunciado (skewness ≈ 2.21), con valores extremos como el de Sudán del Sur (MMR = 1,150 en 2021).

En lugar de eliminar estos casos, se aplicó una transformación logarítmica en base 10 sobre la variable de mortalidad, lo que estabilizó la distribución y redujo la influencia desproporcionada de los valores extremos.

Como ingeniería de variables se construyeron tres variables derivadas: (1) $\log_{10}$(MMR 2021) para capturar el nivel actual de mortalidad en escala normalizada; (2) el cambio porcentual de la última década —$(MMR_{20}^{21} - MMR_{20}^{11}) / MMR_{20}^{11} \times 100$— para capturar la velocidad de mejora; y (3) la brecha absoluta a la meta ODS 3.1, definida como $\text{máx}(MMR_{20}^{21} - 70, 0)$.

3.3. Análisis Exploratorio de Datos (EDA)

Las estadísticas descriptivas del MMR 2021 muestran una media de aproximadamente 235 muertes por cada 100,000 nacidos vivos frente a una mediana de 72, evidenciando la asimetría estructural de los datos. El valor máximo observado es 1,150 (Sudán del Sur). El coeficiente de asimetría de 2.21 confirma que la distribución no se aproxima a la normalidad.

La distribución de la variable objetivo en escala original exhibe una cola derecha muy pronunciada. Tras aplicar la transformación logarítmica, la distribución se acerca a la simetría, cumpliendo de forma aproximada el supuesto que requieren algoritmos como K-Means.

Se identificó una correlación lineal positiva muy alta ($R^2 \approx 0.85$) entre el ranking HDI y el logaritmo de MMR 2021. Esta relación respaldó la decisión de no incluir el IDH como variable de clustering, ya que hacerlo habría sesgado el agrupamiento hacia diferencias económicas conocidas.

Al tratarse de un problema no supervisado no existe variable objetivo con clases predefinidas. Sin embargo, el análisis de la brecha (ver anexo 1) a la meta ODS reveló que aproximadamente el 40% de los países aún no alcanza el umbral de 70 muertes por 100,000 nacidos vivos

establecido para 2030.

Las visualizaciones del EDA permitieron identificar tres patrones estructurales: (1) países de altos ingresos muy por debajo de la meta ODS, (2) países en tránsito con mejoras moderadas pero insuficientes, y (3) países en crisis con MMR extremadamente alta y sin convergencia hacia la meta. Estos patrones anticiparon la estructura de tres clústeres validada con el Método del Codo y el Coeficiente de Silueta.

Desde el punto de vista de la viabilidad empírica, los datos presentan suficiente variabilidad y estructura para soportar un análisis de clustering no supervisado. La heterogeneidad entre países y la ausencia de colinealidad perfecta entre las variables construidas son condiciones necesarias para que K-Means y K-Medoids produzcan agrupaciones significativas.

4. Definición del Problema de Aprendizaje Automático

4.1. Tipo de Problema

El presente estudio se aborda como un problema de Agrupamiento (Clustering) bajo un enfoque de aprendizaje no supervisado. La mortalidad materna es un fenómeno multidimensional donde no existen etiquetas previas de "éxito" o "fracaso" universalmente aplicables a todos los contextos socioeconómicos. El agrupamiento permite descubrir estructuras latentes en los datos, identificando patrones de comportamiento similares entre naciones sin imponer sesgos de clasificación previos.

4.2. Variable Objetivo

Definición precisa: Perfil de Vulnerabilidad y Desempeño Materno (Variable categórica latente).

En lugar de analizar la mortalidad como un número aislado, esta variable sintetiza la situación de un país en relación con sus pares globales y la meta de los ODS. Al ser una variable construida algorítmicamente, su interpretación depende de la estabilidad de los clústeres. Además, está sujeta a la calidad del reporte estadístico de cada país.

4.3. Variables Predictoras

- **Mortalidad Materna 2021.** Es el indicador de estado que mide la magnitud actual de la crisis. Representa la capacidad del sistema de salud en un momento dado. El análisis mostró una distribución con un sesgo masivo a la derecha (presencia de outliers extremos). La aplicación de la transformación logarítmica fue necesaria para estabilizar la varianza, permitiendo que el modelo identifique diferencias sutiles entre países de mortalidad baja y media sin ser dominado por los valores atípicos.

- **Velocidad de cambio Decadal.** Mide la efectividad histórica de las políticas de salud. Permite diferenciar entre países con la misma tasa de mortalidad, pero con trayectorias opuestas

- **Brecha absoluta hacia la meta ODS.** Cuantifica la distancia lineal respecto al compromiso internacional de la Agenda 2030 (<70 por cada 100,000 nacidos vivos) Actúa como un factor de urgencia política.

5. Modelos y Algoritmos

5.1. Modelo baseline.

Clasificación por umbral ODS y Tendencia histórica. Se basa en una clasificación bivariada: primero, la posición estática del país respecto a la Meta ODS 3.1; y segundo, su tendencia histórica calculada mediante la tasa de variación anual entre 2000 y 2021. Esta agrupación sencilla asume que e comportamiento pasado de la tasa de mortalidad es un predictor suficiente del éxito futuro. No es un modelo de aprendizaje automático, sino un análisis descriptivo basado en reglas predefinidas.

Este baseline identificó que el 80% de la carga de mortalidad se concentra en países con tendencias estancadas, revelando que el enfoque tradicional ignora el riesgo de retroceso en naciones con cifras moderadas. Países como República Dominicana o Paraguay serían clasificados simplemente como "En Cumplimiento" al estar por debajo de 70.

5.2. Modelo intermedio

K-Means Clustering (ver anexo 2). Algoritmo de aprendizaje no supervisado que agrupa los 185 países minimizando la varianza interna de cada grupo. Utiliza las tres variables predictoras (MMR logarítmica, Velocidad de Cambio y Brecha ODS). Asume que los clústeres tienen formas aproximadamente esféricas y que la media (centroide) es un representante fiel del grupo. Su ventaja es que es computacionalmente rápido y efectivo para segmentar grandes poblaciones, pero, puede ser sensible a valores extremos.

Se controla mediante el método del codo, seleccionando un numero de clústeres que capture la estructura real sin fragmentar la muestra. En este modelo, el clúster crítico muestra que países como Nigeria o Chad no solo tienen mortalidades altas, sino que su velocidad de cambio es inexistente, dictando que la intervención en estos países debe ser estructural.

5.3. Modelo flexible

K-Medoids (ver anexo 3). Variante más robusta de clustering que utiliza medoides (miembros reales del conjunto de datos) como centros de grupo en lugar de promedios. Es más permisivo con las distribuciones de datos y no requiere que los grupos sean perfectamente esféricos, por lo que es más resistente a outliers evitando que estos distorsionen los grupos generales.

Los medoids (medoides) son los países que el modelo selecciona como los representantes más típicos o "centrales" de cada grupo. Por ejemplo, Uruguay (Medoide del Grupo de Desempeño Sostenido): Actúa como el modelo de éxito. Representa a los países que ya están por debajo de la meta de los ODS y mantienen una tendencia de mejora constante, sirviendo como ejemplo de políticas públicas efectivas y estables.

5.4. Modelo complementario

HDBSCAN (ver anexo 4). Como analisis complementario, se incorporó HDBSCAN (Hierarchical Density-Based Spatial Clustering of Applications with Noise), un algoritmo de agrupamiento basado

en densidad que a diferencia de los metodos anteriores no obliga a los paises a pertenecer a un clúster. Los resultados identificaron que HDBSCAN confirmó con mayor claridad los casos extremos, especialmente los países con menor mortalidad y los de mayor rezago, aun así, este modelo mantiene una proporción importante de países intermedios en una zona de ambigüedad o frontera. Estos resultados concluyen que, en base por los outliers, el fenómeno es más complejo de capturar.

6. Estrategia de Validación

6.1. División de Datos

Dado que este proyecto se formula como un problema de agrupamiento no supervisado no existe una variable objetivo observado que permita una estrategia clásica de train, validation y test, al igual que métricas supervisadas como accuracy o AUC. En este contexto la validación se centró en evaluar si la estructura de grupos identificada era coherente, interpretable y de utilidad hacia los agentes.

6.2. Métricas de Evaluación

Como referencia inicial, se utiliz el baseline descriptivo detallado en secciones anteriores, basado en el umbral ODS de 70 muertes maternas por cada 100,000 nacidos vivos. Este criterio es útil sin embargo es limitado porque no distingue paises con trayectorias distintas además de su interpretabilidad limitada. Por ello se incorporaron métodos de clustering que combinan tanto la mortalidad como la velocidad de cambio en la última decada y la brecha frente a la meta ODS como el K-Means y el K-Medoids.

La métrica interna principal para evaluar la cohesión y separación de clústeres fue el Coeficiente de Silueta. Dicha métrica mostro que existe una estrcutrua razonable en los datos, aunque no perfectamente definida. Además, se utilizó el Adjusted Rand Index (ARI) para comparar la estabilidad entre K-Means y K-Medoids. El valor obtenido (ARI = 0.842) indica que ambos modelos se acercan, por lo que el patrón principal del clustering es robusto frente a cambios en el algoritmo. Por último, como contraste metodológico se exploró HDBSCAN que confirma con claridad los grupos extremos y que existen países intermedios en zona de frontera o ambiguiedad. Estos resultados refuerzan la decisión de mantener el modelo anterior.

Desde el punto de vista social, el error más costoso sería subestimar el riesgo de un país, es decir clasificarlo como relativamente estable o eifciente cuando todavía requiere atención prioritaria. Este tipo de error podría derivar en retiro prematuro de ayuda técnica o financiera pudiendo caer en un retroceso. Por ello, la validación debe ser interpretada bajo un criterio conservador.

7. Consideraciones Éticas

Este proyecto presenta consideraciones éticas importantes relacionadas con sesgo algorítmico, transparencia, estigmatización y rendición de cuentas. El principal riesgo es que las diferencias en la calidad de los datos entre países generen clasificaciones que aparenten objetividad, pero que en realidad reflejen debilidades estructurales en los sistemas estadísticos. Esto es especialmente relevante en países con conflicto o fragilidad institucional, donde la mortalidad materna podría estar subregistrada. Para mitigar este problema, se evitó imputar valores faltantes.

Otro riesgo ético es la estigmatización. Etiquetas como “crítico” o “eficiente” pueden ser útiles para comunicar prioridades, pero no deben interpretarse como juicios permanentes sobre los países. Estas categorías describen patrones observados en los datos y deben entenderse como instrumentos de priorización temporal, no como evaluaciones absolutas. Por ello, el modelo debe utilizarse para orientar apoyo y no para justificar exclusión o castigo.

La transparencia también es central. Se eligió K-Means como modelo principal por su facilidad de interpretación, y se complementó con K-Medoids y HDBSCAN para mostrar que la estructura identificada no depende de un único algoritmo. Aun así, cualquier uso práctico del modelo debe explicitar con claridad qué variables se usaron, qué supuestos se hicieron y cuáles son los límites de la clasificación.

Finalmente, el modelo no debe reemplazar el juicio experto. Las decisiones sobre asignación de recursos o ayuda internacional deben mantenerse bajo supervisión institucional.

8. Limitaciones

En cuanto a la calidad de la información, el análisis enfrenta un sesgo de medición estructural, ya que los países con mayores tasas de mortalidad suelen poseer los sistemas de registro civil más débiles, lo que sugiere una posible subestimación de las cifras reales. Además, la "congelación" de datos en varios territorios desde 2017 indica el uso de proyecciones o imputaciones por parte de los organismos fuente, lo que puede distorsionar el cálculo de las tendencias y la velocidad de cambio de la última década.

Desde el ámbito metodológico, el uso de K-Means asume una geometría de clústeres esférica y de tamaños similares que no siempre refleja la complejidad de la realidad sanitaria global. Aunque se implementaron validaciones con K-Medoids para aportar robustez frente a valores atípicos, los resultados siguen siendo altamente sensibles a la escala y a la transformación logarítmica de las variables, lo que requiere una interpretación cautelosa de las agrupaciones resultantes.

Finalmente, el estudio se basa en supuestos rígidos, como considerar los datos de 2021 como un estado actual definitivo y el umbral de 70 muertes como una meta universalmente aplicable. Estas restricciones limitan la generalización de los hallazgos, los cuales son válidos únicamente para el periodo analizado.

9. Recomendaciones de Implementación

El modelo de clustering debe integrarse como una herramienta estratégica de priorización para organismos de cooperación internacional y ministerios de salud. Su función principal es segmentar la urgencia de intervención: el clúster Crítico para asistencia humanitaria inmediata, el clúster de transición para apoyo técnico focalizado en revertir estancamientos, y el clúster eficiente como modelo de transferencia de buenas prácticas.

La implementación operativa se podría dar a través de un dashboard interactivo que permitiría a los tomadores de decisión visualizar en tiempo real la posición de cada país, monitorear señales de retroceso y generar reportes ejecutivos automatizados. Se recomienda iniciar un programa piloto con 10 países del clúster crítico, utilizando el dashboard como insumo principal para la asignación de fondos en iniciativas como Every Woman Every Child, complementando el juicio experto con evidencia basada en datos.

Finalmente, el éxito de la implementación se puede medir a través de indicadores de impacto específicos: la reducción en los tiempos de respuesta para intervenciones, el porcentaje de países en crisis con planes de acción activos en menos de 12 meses y, fundamentalmente, la reducción medible de la brecha hacia la meta ODS en aquellos países identificados por el dashboard en situación de estancamiento.

Declaración de uso de IA: En la preparación de este documento se utilizó Claude (Anthropic) como asistente de escritura para organizar ideas, mejorar la redacción y verificar la coherencia técnica. Todas las decisiones metodológicas, la interpretación de resultados y el contenido sustantivo son propios del equipo de trabajo.

Anexos

Anexo 1. Analisís de Brechas

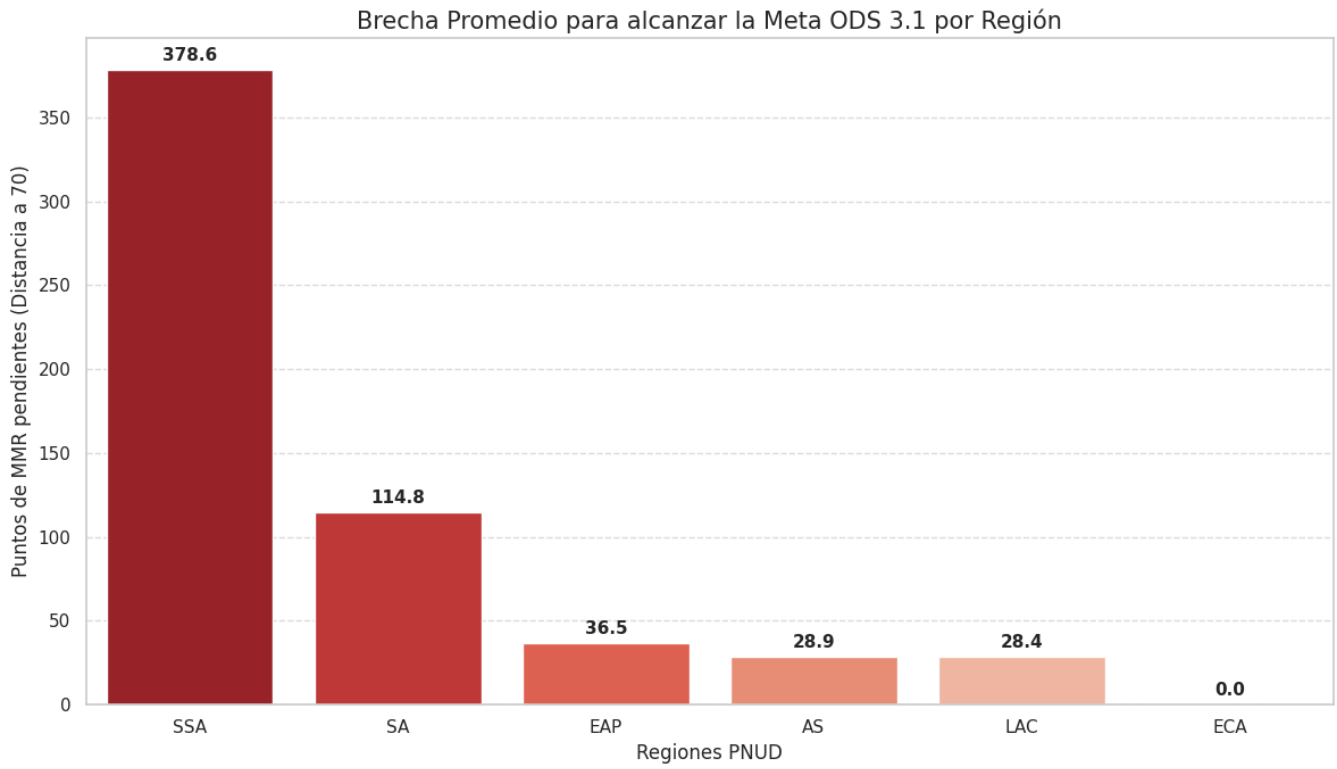

Anexo 2. K - Means

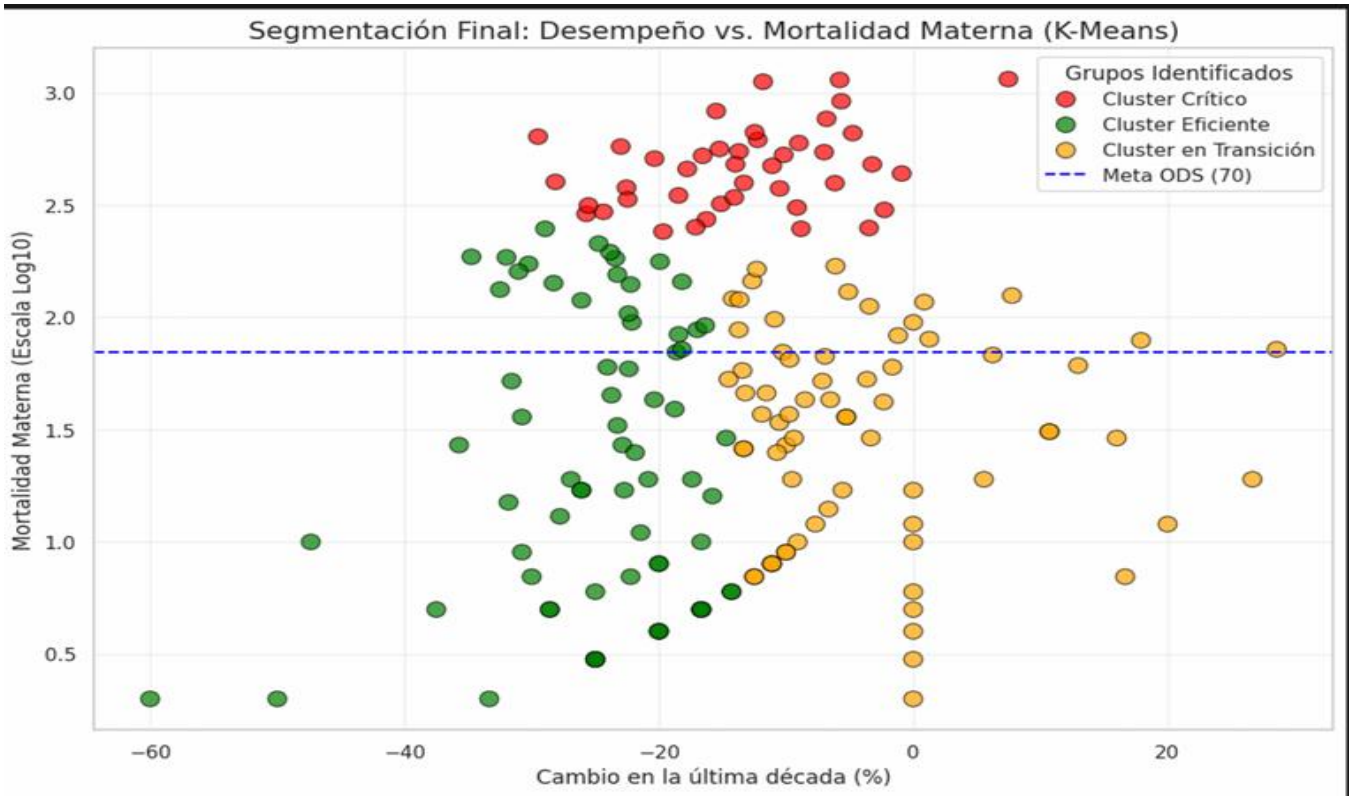

Anexo 3. K - Medoids

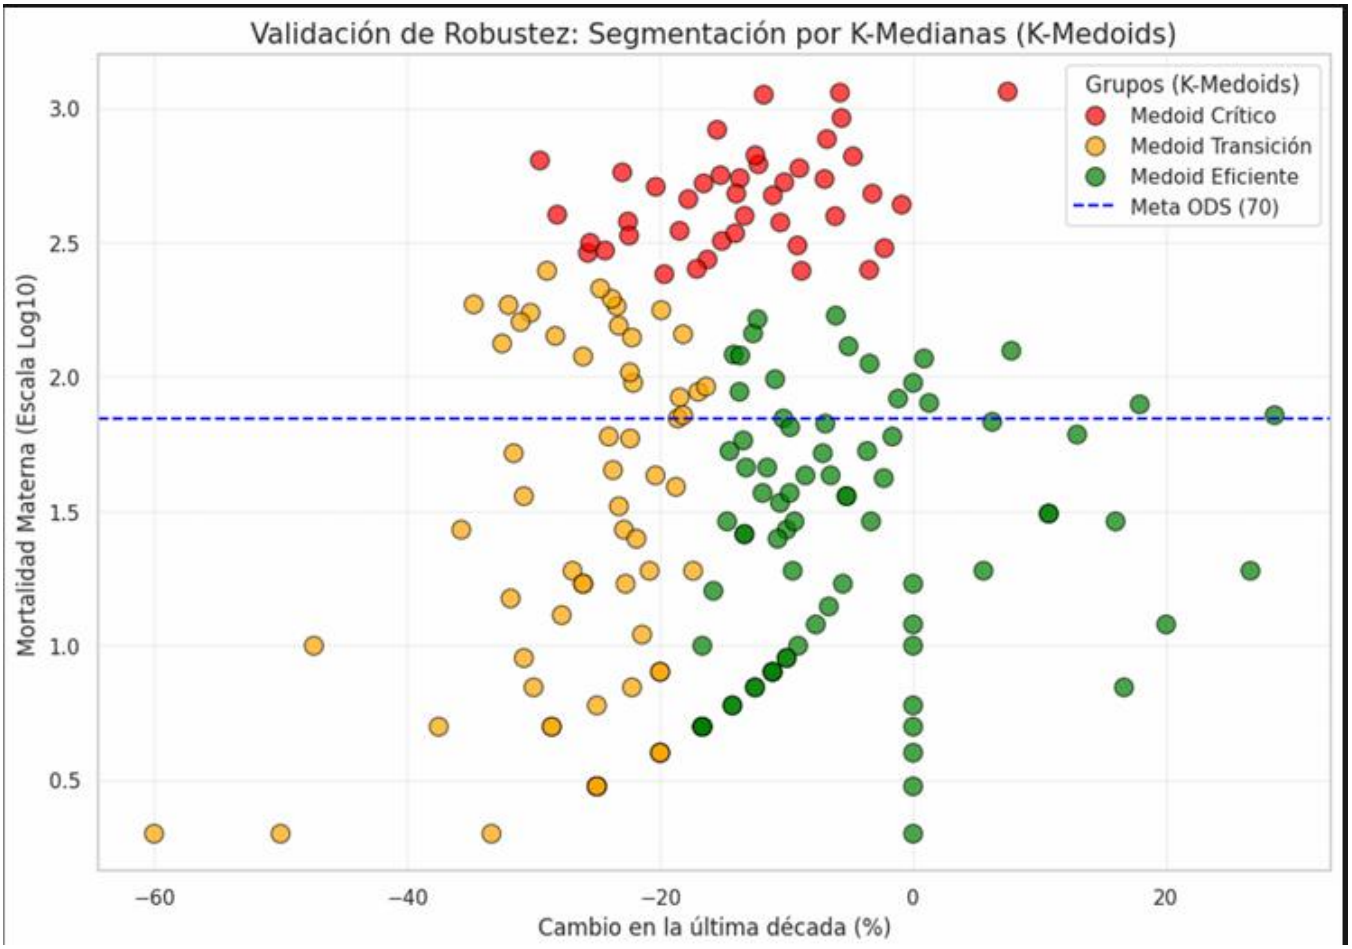
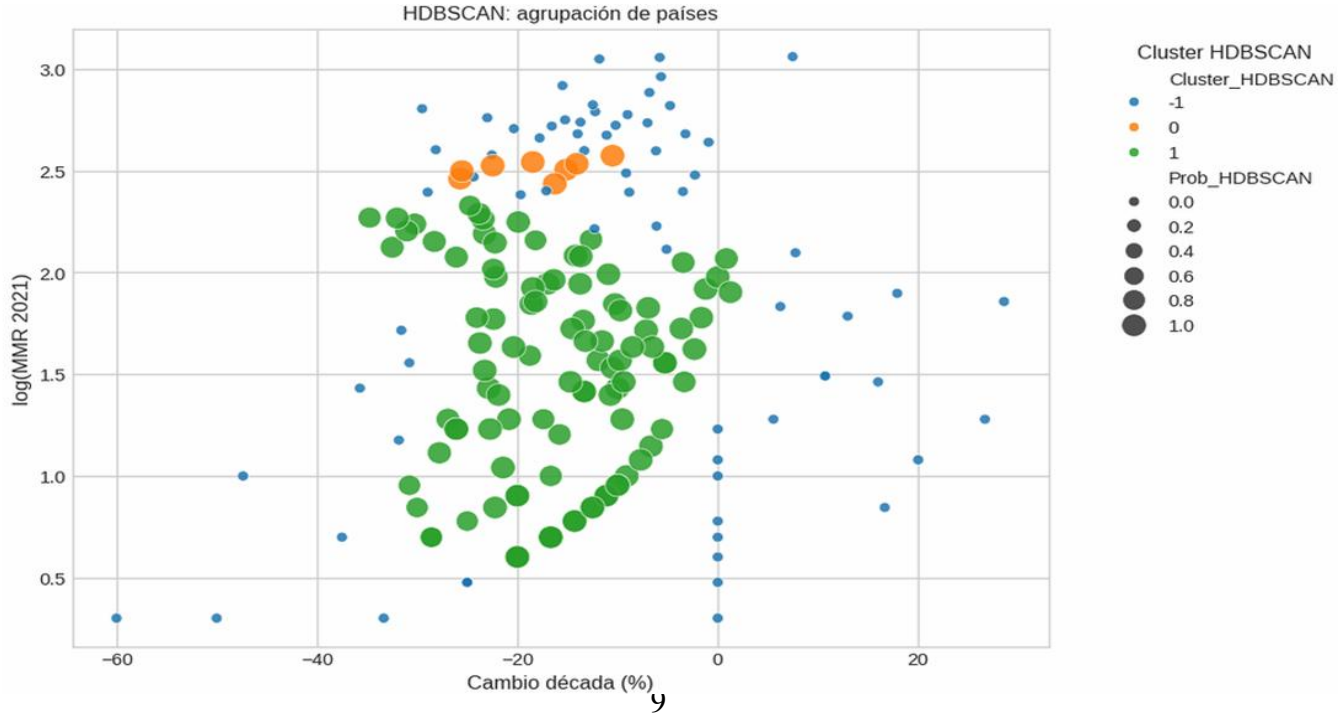
Anexo 4. HDBSCAN